ESTUDO DIRIGIDO 3

Fundamentos de Inteligência Artificial Novembro/2026

Dados do Trabalho

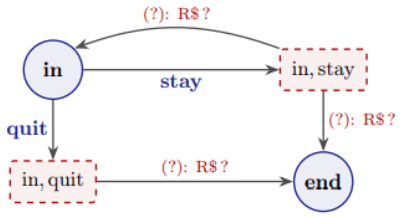
Titulo do trabalho:	Estudo Dirigido 3
Alunos:	Thales Vasconcelos – 2018019630 Pedro Vieira – 2016111725

1 Exercício 1

Exercício 1 — Modelagem de um MDP

Considere a seguinte variante do *jogo dos dados* visto em aula. Em cada rodada o jogador está no estado **in** e escolhe uma entre duas ações:

- **stay**: recebe **R$ 3** e lança um dado de **quatro faces**. Se sair 1, 2 ou 3, o jogo continua (volta ao estado **in**); se sair 4, o jogo termina.
- **quit**: recebe **R$ 8** e o jogo termina imediatamente.



(a) Escreva formalmente o MDP: o conjunto de estados $\mathcal{S}$, o estado inicial s_{start}, o conjunto de ações $\mathcal{A}(s)$ de cada estado e a função $\text{IsEnd}(s)$.

(b) Complete a tabela de transições, uma linha por tripla (s, a, s') com $T(s, a, s') > 0$, e verifique que $\sum_{s' \in \mathcal{S}} T(s, a, s') = 1$ para cada par (s, a).

(c) Escreva $R(s, a, s')$ para cada uma dessas triplas. Note que a recompensa é a mesma nas duas saídas da ação **stay**: explique por que isso não torna o par (s, a) determinístico.

(d) Reproduza o grafo acima substituindo cada "?" pelos valores corretos de probabilidade e recompensa. Identifique no desenho quais nós são *estados* e quais são *nós de chance*.

(e) Liste $\text{Succ}(\text{in}, \text{stay})$ e $\text{Succ}(\text{in}, \text{quit})$.

(f) Este problema poderia ser formulado como um *problema de busca* (no sentido visto no início do curso)? Justifique indicando exatamente qual elemento do MDP impede essa formulação.

1.1 Item (a)

O Processo de Decisão de Markov (MDP) pode ser definido formalmente pelos seguintes elementos:

- **Conjunto de estados:**

$$S = \{in, end\}$$

em que in representa o jogo em andamento e end representa o estado terminal.

- **Estado inicial:**

$$s_{\text{start}} = in$$

- **Conjunto de ações disponíveis:**

$$A(s) = \begin{cases} \{stay, quit\}, & \text{se } s = in, \\ \emptyset, & \text{se } s = end. \end{cases}$$

- **Função de identificação do estado terminal:**

$$IsEnd(s) = \begin{cases} \text{True}, & \text{se } s = end, \\ \text{False}, & \text{se } s = in. \end{cases}$$

1.2 Item (b)

A função de transição $T(s, a, s')$ representa a probabilidade de alcançar o estado s' ao executar a ação a no estado s.

As transições possíveis são apresentadas na Tabela 1.

Tabela 1: Probabilidades de transição do MDP

s	a	s'	$T(s, a, s')$
in	$stay$	in	$\frac{3}{4}$
in	$stay$	end	$\frac{1}{4}$
in	$quit$	end	1

Para verificar a validade das probabilidades, devemos garantir que:

$$\sum_{s' \in S} T(s, a, s') = 1$$

para cada par (s, a) com ação disponível.

Ação stay:

Como três das quatro faces do dado mantêm o jogador no estado in e uma encerra o jogo:

$$\begin{aligned} \sum_{s' \in S} T(in, stay, s') &= T(in, stay, in) + T(in, stay, end) \\ &= \frac{3}{4} + \frac{1}{4} \\ &= 1. \end{aligned}$$

Ação quit:

Como a ação $quit$ encerra o jogo imediatamente:

$$\sum_{s' \in S} T(in, quit, s') = T(in, quit, in) + T(in, quit, end)$$
$$= 0 + 1$$
$$= 1.$$

Portanto, todas as distribuições de probabilidade de transição são válidas, pois suas probabilidades somam 1 para cada par estado-ação.

1.3 Item (c)

A função de recompensa $R(s, a, s')$ representa a recompensa recebida ao executar a ação a no estado s e alcançar o estado s'.

As recompensas das transições são:

$$R(in, stay, in) = 3,$$
$$R(in, stay, end) = 3,$$
$$R(in, quit, end) = 8.$$

A ação $stay$ fornece uma recompensa de R$ 3, independentemente do resultado do lançamento do dado. Por outro lado, a ação $quit$ fornece uma recompensa de R$ 8 e encerra imediatamente o jogo.

Embora a recompensa da ação $stay$ seja sempre a mesma, isso não torna o par $(in, stay)$ determinístico, pois existem dois estados sucessores possíveis:

$$T(in, stay, in) = \frac{3}{4}$$

$$T(in, stay, end) = \frac{1}{4}$$

Portanto, a recompensa da ação $stay$ é determinística, mas a transição de estados é estocástica, uma vez que o próximo estado depende do resultado aleatório do lançamento do dado.

1.4 Item (d)

O grafo do MDP é apresentado na Figura 1, com as probabilidades de transição e suas respectivas recompensas.

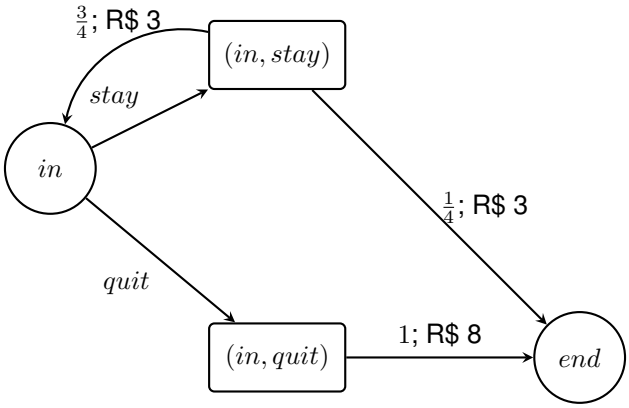


Figura 1: Grafo do MDP com probabilidades de transição e recompensas.

No grafo, os nós circulares representam os **estados** do MDP (in e end), enquanto os nós retangulares representam os **nós de chance** associados aos pares estado-ação $(in, stay)$ e $(in, quit)$.

A partir do estado in, o jogador escolhe entre as ações $stay$ e $quit$.

Ao escolher $stay$, recebe R$ 3 e pode retornar ao estado in com probabilidade $\frac{3}{4}$, ou alcançar o estado terminal end com probabilidade $\frac{1}{4}$.

Ao escolher $quit$, recebe R$ 8 e alcança o estado terminal end com probabilidade 1.

1.5 Item (e)

O conjunto de estados sucessores $Succ(s, a)$ contém todos os estados que podem ser alcançados a partir do estado s após executar a ação a, com probabilidade de transição maior que zero.

Para a ação $stay$, o jogador pode permanecer no estado in, com probabilidade $\frac{3}{4}$, ou alcançar o estado terminal end, com probabilidade $\frac{1}{4}$. Portanto:

$$Succ(in, stay) = \{in, end\}$$

Para a ação $quit$, o jogo termina imediatamente, de modo que o único estado sucessor possível é end. Assim:

$$Succ(in, quit) = \{end\}$$

1.6 Item (f)

O problema não pode ser formulado diretamente como um problema de busca tradicional determinística, pois apresenta transições estocásticas.

Em um problema de busca determinística, a função de transição associa cada par estado-ação (s, a) a um único estado sucessor s'.

Entretanto, no MDP apresentado, a ação $stay$ possui dois resultados possíveis:

$$T(in, stay, in) = \frac{3}{4}$$

$$T(in, stay, end) = \frac{1}{4}$$

Assim, o próximo estado não é determinado exclusivamente pela ação escolhida, mas também pelo resultado aleatório do lançamento do dado.

Portanto, o elemento que impede a formulação direta como um problema de busca determinística é a **função de transição probabilística** $T(s, a, s')$, que permite múltiplos estados sucessores para um mesmo par estado-ação.

Nesse caso, a modelagem como MDP é mais adequada, pois permite representar tanto as probabilidades de transição quanto as recompensas associadas às decisões.

2 Exercício 2

Exercício 2 — Avaliação de política

Para o MDP do Exercício 1, considere as duas políticas determinísticas $\pi_1(\text{in}) = \text{stay}$ e $\pi_2(\text{in}) = \text{quit}$.

(a) Escreva a equação de Bellman para $V_\pi(\text{in})$ sob a política π_1, com $\gamma = 1$. Lembre-se de que

$V_\pi(\text{end}) = 0$.

(b) Resolva a equação do item (a) em forma fechada e obtenha $V_{\pi_1}(\text{in})$.

(c) Execute a **avaliação iterativa de política** a partir de $V_{\pi_1}^{(0)}(\text{in}) = 0$ e preencha a tabela abaixo ($\gamma = 1$). Comente o comportamento da sequência.

t	0	1	2	3	4
$V_{\pi_1}^{(t)}(\text{in})$	0				

(d) Calcule $V_{\pi_2}(\text{in})$ e indique qual das duas políticas é melhor quando $\gamma = 1$.

(e) Refaça os itens (b) e (d) com $\gamma = 0{,}5$. A política ótima muda? Explique *intuitivamente* o que o fator de desconto está fazendo com a decisão do jogador.

(f) **(Intermediário)** Determine o valor de $\gamma \in [0, 1]$ para o qual as duas políticas são *equivalentes*, isto é, $V_{\pi_1}(\text{in}) = V_{\pi_2}(\text{in})$.

Dica

Sob uma política determinística, a equação de Bellman em um estado não terminal é $V_\pi(s) = \sum_{s'} T\big(s, \pi(s), s'\big)\left[R\big(s, \pi(s), s'\big) + \gamma V_\pi(s')\right]$. No item (b), isole $V_\pi(\text{in})$: a equação é linear porque **in** aparece dos dois lados.

2.1 Item (a)

Considere a política determinística π_1, na qual o jogador sempre escolhe a ação $stay$:

$$\pi_1(in) = stay$$

A equação de Bellman para avaliação de uma política π é dada por:

$$V_\pi(s) = \sum_{s' \in S} T(s, \pi(s), s') \left[R(s, \pi(s), s') + \gamma V_\pi(s')\right]$$

Para a política π_1, considerando $\gamma = 1$ e $V_{\pi_1}(end) = 0$, temos:

$$
\begin{aligned}
V_{\pi_1}(in) &= \frac{3}{4}\left[3 + V_{\pi_1}(in)\right] + \frac{1}{4}\left[3 + V_{\pi_1}(end)\right] \\
&= \frac{3}{4}\left[3 + V_{\pi_1}(in)\right] + \frac{1}{4}(3 + 0) \\
&= \frac{9}{4} + \frac{3}{4}V_{\pi_1}(in) + \frac{3}{4}
\end{aligned}
$$

Portanto, a equação de Bellman para a política π_1 é:

$$
\boxed{V_{\pi_1}(in) = 3 + \frac{3}{4}V_{\pi_1}(in)}
$$

2.2 Item (b)

A partir da equação de Bellman obtida no item (a), temos:

$$
V_{\pi_1}(in) = 3 + \frac{3}{4}V_{\pi_1}(in)
$$

Isolando $V_{\pi_1}(in)$:

$$
\begin{aligned}
V_{\pi_1}(in) - \frac{3}{4}V_{\pi_1}(in) &= 3 \\
\left(1 - \frac{3}{4}\right)V_{\pi_1}(in) &= 3 \\
\frac{1}{4}V_{\pi_1}(in) &= 3 \\
V_{\pi_1}(in) &= \frac{3}{1/4}
\end{aligned}
$$

Portanto:

$$
\boxed{V_{\pi_1}(in) = 12}
$$

Assim, seguindo a política π_1, na qual o jogador sempre escolhe a ação $stay$, a recompensa total esperada é de R$ 12,00.

Esse resultado considera todas as rodadas possíveis até o encerramento do jogo, com fator de desconto $\gamma = 1$.

2.3 Item (c)

A avaliação iterativa da política π_1 é realizada a partir do valor inicial:

$$V_{\pi_1}^{(0)}(in) = 0$$

Considerando $\gamma = 1$, a equação de atualização é:

$$V_{\pi_1}^{(t+1)}(in) = 3 + \frac{3}{4} V_{\pi_1}^{(t)}(in)$$

Aplicando a equação sucessivamente:

$$V_{\pi_1}^{(1)}(in) = 3 + \frac{3}{4}(0) = 3$$

$$V_{\pi_1}^{(2)}(in) = 3 + \frac{3}{4}(3) = 5{,}25$$

$$V_{\pi_1}^{(3)}(in) = 3 + \frac{3}{4}(5{,}25) = 6{,}9375$$

$$V_{\pi_1}^{(4)}(in) = 3 + \frac{3}{4}(6{,}9375) = 8{,}203125$$

Os resultados são apresentados na Tabela 2.

Tabela 2: Avaliação iterativa da política π_1

t	0	1	2	3	4
$V_{\pi_1}^{(t)}(in)$	0	3	5,25	6,9375	8,203125

Observa-se que a sequência de valores é monotonicamente crescente, aproximando-se progressivamente do valor exato obtido no item (b):

$$\lim_{t \to \infty} V_{\pi_1}^{(t)}(in) = 12$$

A convergência ocorre porque, a cada iteração, a diferença em relação ao valor exato é multiplicada por $\frac{3}{4}$, tornando-se progressivamente menor.

2.4 Item (d)

Considere a política determinística π_2, na qual o jogador sempre escolhe a ação $quit$:

$$\pi_2(in) = quit$$

Pela equação de Bellman, considerando $\gamma = 1$, temos:

$$\begin{aligned} V_{\pi_2}(in) &= T(in, quit, end)\,[R(in, quit, end) + V_{\pi_2}(end)] \\ &= 1 \cdot (8 + 0) \\ &= 8 \end{aligned}$$

Portanto:

$$\boxed{V_{\pi_2}(in) = 8}$$

Comparando os valores das duas políticas:

$$\begin{aligned} V_{\pi_1}(in) &= 12 \\ V_{\pi_2}(in) &= 8 \end{aligned}$$

Como:

$$V_{\pi_1}(in) > V_{\pi_2}(in)$$

conclui-se que a política π_1, que sempre escolhe a ação $stay$, é a melhor para $\gamma = 1$.

Isso ocorre porque a possibilidade de continuar recebendo recompensas de R$ 3 nas rodadas seguintes resulta em uma recompensa total esperada de R$ 12, superior aos R$ 8 recebidos imediatamente pela ação $quit$.

2.5 Item (e)

Considerando o fator de desconto $\gamma = 0{,}5$, recalculamos os valores das políticas π_1 e π_2.

Política $\pi_1(in) = stay$:

Pela equação de Bellman:

$$\begin{aligned} V_{\pi_1}(in) &= \frac{3}{4}\,[3 + 0{,}5 V_{\pi_1}(in)] + \frac{1}{4}(3 + 0) \\ &= 3 + 0{,}375 V_{\pi_1}(in) \end{aligned}$$

Isolando $V_{\pi_1}(in)$:

$$\begin{aligned} V_{\pi_1}(in) - 0{,}375V_{\pi_1}(in) &= 3 \\ 0{,}625V_{\pi_1}(in) &= 3 \\ V_{\pi_1}(in) &= \frac{3}{0{,}625} \\ &= 4{,}8 \end{aligned}$$

Portanto:

$$\boxed{V_{\pi_1}(in) = 4{,}8}$$

Política $\pi_2(in) = quit$:

Como a ação $quit$ encerra imediatamente o jogo, não existem recompensas futuras a serem descontadas.

$$\begin{aligned} V_{\pi_2}(in) &= 1 \cdot [8 + 0{,}5(0)] \\ &= 8 \end{aligned}$$

Portanto:

$$\boxed{V_{\pi_2}(in) = 8}$$

Comparação das políticas:

$$V_{\pi_2}(in) = 8 > 4{,}8 = V_{\pi_1}(in)$$

Logo, a política ótima muda de $stay$ para $quit$ quando o fator de desconto passa de $\gamma = 1$ para $\gamma = 0{,}5$.

Isso ocorre porque o fator de desconto reduz a importância das recompensas futuras em relação às recompensas imediatas.

Com $\gamma = 1$, todas as recompensas possuem o mesmo peso, independentemente de quando são recebidas, favorecendo a ação $stay$.

Já com $\gamma = 0{,}5$, as recompensas futuras perdem valor progressivamente, tornando mais vantajoso receber R$ 8 imediatamente por meio da ação $quit$.

2.6 Item (f)

Para determinar o fator de desconto γ que torna as duas políticas equivalentes, devemos encontrar o valor que satisfaz:

$$V_{\pi_1}(in) = V_{\pi_2}(in)$$

Política $\pi_1(in) = stay$:

Aplicando a equação de Bellman para um fator de desconto genérico γ:

$$\begin{aligned} V_{\pi_1}(in) &= \frac{3}{4}\left[3 + \gamma V_{\pi_1}(in)\right] + \frac{1}{4}(3+0) \\ &= 3 + \frac{3}{4}\gamma V_{\pi_1}(in) \end{aligned}$$

Isolando $V_{\pi_1}(in)$:

$$\begin{aligned} V_{\pi_1}(in) - \frac{3}{4}\gamma V_{\pi_1}(in) &= 3 \\ V_{\pi_1}(in)\left(1 - \frac{3}{4}\gamma\right) &= 3 \end{aligned}$$

Portanto:

$$V_{\pi_1}(in) = \frac{3}{1 - \frac{3}{4}\gamma}$$

Política $\pi_2(in) = quit$:

Como a ação $quit$ encerra imediatamente o jogo:

$$V_{\pi_2}(in) = 8$$

Igualando os valores das políticas:

$$\frac{3}{1-\frac{3}{4}\gamma} = 8$$

$$3 = 8\left(1-\frac{3}{4}\gamma\right)$$

$$3 = 8 - 6\gamma$$

$$6\gamma = 5$$

$$\gamma = \frac{5}{6}$$

Assim, o fator de desconto que torna as duas políticas equivalentes é:

$$\boxed{\gamma = \frac{5}{6} \approx 0{,}8333}$$

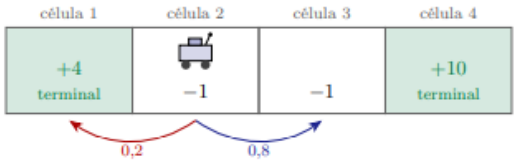
Nesse ponto, ambas as políticas apresentam a mesma recompensa total esperada de R$ 8.

Para $\gamma < \frac{5}{6}$, a política $quit$ é mais vantajosa, enquanto para $\gamma > \frac{5}{6}$, a política $stay$ apresenta maior valor esperado.

3 Exercício 3

Exercício 3 — Iteração de valor em um corredor

Um rover percorre um corredor de quatro células. As células 1 e 4 são **terminais**: a célula 1 é um ponto de coleta que paga +4 e a célula 4 é a base, que paga +10. Nas células 2 e 3 o rover escolhe entre as ações **E** (esquerda) e **D** (direita). As rodas patinam: a ação leva à célula pretendida com probabilidade 0,8 e à célula *oposta* com probabilidade 0,2. Toda transição que termina em uma célula não terminal paga −1. Adote $\gamma = 1$.



resultados da ação **D** tomada na célula 2

(a) Escreva $\mathcal{A}(s)$ para $s \in \{2,3\}$ e a tabela completa de $T(s,a,s')$ e $R(s,a,s')$ (oito triplas ao todo).

(b) Execute o algoritmo **iteração de valor** (*value iteration*) para $t = 1,2,3$, partindo de $V^{\star(0)}(s) = 0$ para todo s. Preencha a tabela a seguir, apresentando também os Q-valores intermediários $Q^{\star(t)}(s,\mathbf{E})$ e $Q^{\star(t)}(s,\mathbf{D})$.

t	$V^{\star(t)}(2)$	$\pi^{\star(t)}(2)$	$V^{\star(t)}(3)$	$\pi^{\star(t)}(3)$
0	0	—	0	—
1				
2				
3				

(c) A ação preferida na célula 2 **muda** entre $t = 1$ e $t = 2$. Explique por quê, em termos do que $V^{\star(t)}$ representa (o valor ótimo quando restam t passos).

(d) **(Desafio)** Suponha que a política ótima seja $\pi^\star(2) = \pi^\star(3) = \mathbf{D}$. Escreva as duas equações de Bellman correspondentes, resolva o sistema linear 2×2 e obtenha os valores exatos $V^\star(2)$ e $V^\star(3)$. Em seguida *verifique* que a ação **E** é de fato pior em ambos os estados.

(e) Escreva a política ótima $\pi^\star$ e explique por que o rover prefere atravessar o corredor mesmo correndo o risco de escorregar para a célula 1.

3.1 Item (a)

O conjunto de estados do MDP é dado por:

$$S = \{1, 2, 3, 4\}$$

As células 1 e 4 são estados terminais, enquanto as células 2 e 3 permitem a escolha entre as ações E (esquerda) e D (direita).

Assim, os conjuntos de ações disponíveis são:

$$A(2) = A(3) = \{E, D\}$$

As probabilidades de transição dependem do movimento escolhido pelo rover. A direção pretendida ocorre com probabilidade $0{,}8$, enquanto o movimento na direção oposta ocorre com probabilidade $0{,}2$.

As recompensas são determinadas pelo estado de destino:

$$R(s, a, s') = \begin{cases} +4, & \text{se } s' = 1, \\ -1, & \text{se } s' \in \{2, 3\}, \\ +10, & \text{se } s' = 4. \end{cases}$$

A Tabela 3 apresenta as oito transições possíveis do MDP.

Tabela 3: Transições e recompensas do rover

s	a	s'	$T(s, a, s')$	$R(s, a, s')$
2	E	1	$0{,}8$	$+4$
2	E	3	$0{,}2$	-1
2	D	3	$0{,}8$	-1
2	D	1	$0{,}2$	$+4$
3	E	2	$0{,}8$	-1
3	E	4	$0{,}2$	$+10$
3	D	4	$0{,}8$	$+10$
3	D	2	$0{,}2$	-1

Para cada par estado-ação (s, a), a soma das probabilidades das transições possíveis é igual a 1:

$$\sum_{s' \in S} T(s, a, s') = 0{,}8 + 0{,}2 = 1$$

Portanto, as distribuições de probabilidade de transição são válidas para todas as ações disponíveis.

3.2 Item (b)

O algoritmo de iteração de valor (*Value Iteration*) calcula iterativamente os valores ótimos dos estados, considerando as recompensas imediatas e os valores esperados dos estados sucessores.

A equação de atualização dos Q-valores é:

$$Q^{\star(t)}(s,a) = \sum_{s' \in S} T(s,a,s') \left[R(s,a,s') + \gamma V^{\star(t-1)}(s') \right]$$

O valor ótimo e a ação escolhida são dados por:

$$V^{\star(t)}(s) = \max_{a \in A(s)} Q^{\star(t)}(s,a)$$

$$\pi^{\star(t)}(s) = \arg\max_{a \in A(s)} Q^{\star(t)}(s,a)$$

Consideramos $\gamma = 1$ e os valores iniciais:

$$V^{\star(0)}(s) = 0, \quad \forall s \in S$$

Como as células 1 e 4 são terminais, seus valores permanecem iguais a zero em todas as iterações.

Iteração 1

Utilizando os valores iniciais iguais a zero:

Célula 2:

$$\begin{aligned} Q^{\star(1)}(2,E) &= 0{,}8(4) + 0{,}2(-1) \\ &= 3 \end{aligned}$$

$$\begin{aligned} Q^{\star(1)}(2,D) &= 0{,}8(-1) + 0{,}2(4) \\ &= 0 \end{aligned}$$

Logo:

$$V^{\star(1)}(2) = 3, \qquad \pi^{\star(1)}(2) = E$$

Célula 3:

$$
\begin{aligned}
Q^{\star(1)}(3, E) &= 0{,}8(-1) + 0{,}2(10) \\
&= 1{,}2 \\
Q^{\star(1)}(3, D) &= 0{,}8(10) + 0{,}2(-1) \\
&= 7{,}8
\end{aligned}
$$

Logo:

$$
V^{\star(1)}(3) = 7{,}8, \qquad \pi^{\star(1)}(3) = D
$$

Iteração 2

Utilizando os valores da primeira iteração:

Célula 2:

$$
\begin{aligned}
Q^{\star(2)}(2, E) &= 0{,}8(4) + 0{,}2(-1 + 7{,}8) \\
&= 4{,}56 \\
Q^{\star(2)}(2, D) &= 0{,}8(-1 + 7{,}8) + 0{,}2(4) \\
&= 6{,}24
\end{aligned}
$$

Logo:

$$
V^{\star(2)}(2) = 6{,}24, \qquad \pi^{\star(2)}(2) = D
$$

Célula 3:

$$
\begin{aligned}
Q^{\star(2)}(3, E) &= 0{,}8(-1 + 3) + 0{,}2(10) \\
&= 3{,}6 \\
Q^{\star(2)}(3, D) &= 0{,}8(10) + 0{,}2(-1 + 3) \\
&= 8{,}4
\end{aligned}
$$

Logo:

$$
V^{\star(2)}(3) = 8{,}4, \qquad \pi^{\star(2)}(3) = D
$$

Iteração 3

Utilizando os valores da segunda iteração:

Célula 2:

$$\begin{aligned} Q^{\star(3)}(2,E) &= 0{,}8(4) + 0{,}2(-1+8{,}4) \\ &= 4{,}68 \\ Q^{\star(3)}(2,D) &= 0{,}8(-1+8{,}4) + 0{,}2(4) \\ &= 6{,}72 \end{aligned}$$

Logo:

$$V^{\star(3)}(2) = 6{,}72, \qquad \pi^{\star(3)}(2) = D$$

Célula 3:

$$\begin{aligned} Q^{\star(3)}(3,E) &= 0{,}8(-1+6{,}24) + 0{,}2(10) \\ &= 6{,}192 \\ Q^{\star(3)}(3,D) &= 0{,}8(10) + 0{,}2(-1+6{,}24) \\ &= 9{,}048 \end{aligned}$$

Logo:

$$V^{\star(3)}(3) = 9{,}048, \qquad \pi^{\star(3)}(3) = D$$

Tabela de resultados

A Tabela 4 apresenta os valores ótimos e as ações selecionadas em cada iteração.

Tabela 4: Resultados da iteração de valor

t	$V^{\star(t)}(2)$	$\pi^{\star(t)}(2)$	$V^{\star(t)}(3)$	$\pi^{\star(t)}(3)$
0	0	–	0	–
1	3	E	7,8	D
2	6,24	D	8,4	D
3	6,72	D	9,048	D

Observa-se que, na primeira iteração, a ação preferida na célula 2 é E. Entretanto, a partir da

segunda iteração, a ação preferida passa a ser D.

Isso ocorre porque o algoritmo passa a considerar as recompensas futuras associadas aos estados sucessores.

3.3 Item (c)

A mudança da ação preferida na célula 2 ocorre porque $V^{\star(t)}(s)$ representa a recompensa total esperada máxima quando restam t passos de decisão.

Na primeira iteração ($t = 1$), o algoritmo considera apenas a recompensa imediata. Assim, a ação E é preferida, pois apresenta maior valor esperado:

$$Q^{\star(1)}(2, E) = 3 > Q^{\star(1)}(2, D) = 0$$

Entretanto, na segunda iteração ($t = 2$), o algoritmo considera também o valor esperado de uma ação futura.

Nesse caso, seguir para a direita permite alcançar a célula 3, de onde existe uma alta probabilidade de chegar à célula terminal 4, que oferece recompensa de $+10$.

Consequentemente, os valores passam a ser:

$$Q^{\star(2)}(2, D) = 6{,}24 > Q^{\star(2)}(2, E) = 4{,}56$$

Portanto, a ação preferida muda de E para D, pois, ao considerar um horizonte maior de decisões, o ganho esperado de avançar em direção à célula 4 supera a vantagem imediata de seguir para a célula 1.

3.4 Item (d)

Considerando a política ótima proposta:

$$\pi^\star(2) = \pi^\star(3) = D$$

e o fator de desconto $\gamma = 1$, podemos determinar os valores ótimos por meio das equações de Bellman.

Equação para a célula 2:

Ao escolher D, o rover alcança a célula 3 com probabilidade $0{,}8$ ou a célula terminal 1 com

probabilidade $0{,}2$.

$$\begin{aligned} V^\star(2) &= 0{,}8[-1 + V^\star(3)] + 0{,}2(4) \\ &= -0{,}8 + 0{,}8V^\star(3) + 0{,}8 \end{aligned}$$

Portanto:

$$V^\star(2) = 0{,}8V^\star(3)$$

Equação para a célula 3:

Ao escolher D, o rover alcança a célula terminal 4 com probabilidade $0{,}8$ ou retorna à célula 2 com probabilidade $0{,}2$.

$$\begin{aligned} V^\star(3) &= 0{,}8(10) + 0{,}2[-1 + V^\star(2)] \\ &= 8 - 0{,}2 + 0{,}2V^\star(2) \end{aligned}$$

Portanto:

$$V^\star(3) = 7{,}8 + 0{,}2V^\star(2)$$

Resolução do sistema linear:

As duas equações formam o sistema:

$$\begin{cases} V^\star(2) - 0{,}8V^\star(3) = 0 \\ -0{,}2V^\star(2) + V^\star(3) = 7{,}8 \end{cases}$$

Substituindo a primeira equação na segunda:

$$\begin{aligned} V^\star(3) &= 7{,}8 + 0{,}2[0{,}8V^\star(3)] \\ &= 7{,}8 + 0{,}16V^\star(3) \end{aligned}$$

Isolando:

$$\begin{aligned} 0{,}84V^\star(3) &= 7{,}8 \\ V^\star(3) &= \frac{7{,}8}{0{,}84} \\ V^\star(3) &= \frac{65}{7} \end{aligned}$$

Substituindo na primeira equação:

$$\begin{aligned} V^\star(2) &= 0{,}8\left(\frac{65}{7}\right) \\ &= \frac{52}{7} \end{aligned}$$

Portanto, os valores exatos são:

$$\boxed{V^\star(2) = \frac{52}{7} \approx 7{,}4286}$$

$$\boxed{V^\star(3) = \frac{65}{7} \approx 9{,}2857}$$

Verificação da ação E:

Para confirmar que a política proposta é ótima, calculamos os Q-valores da ação E utilizando os valores encontrados.

Célula 2:

$$\begin{aligned} Q^\star(2, E) &= 0{,}8(4) + 0{,}2[-1 + V^\star(3)] \\ &= 0{,}8(4) + 0{,}2\left(-1 + \frac{65}{7}\right) \\ &= \frac{34}{7} \approx 4{,}8571 \end{aligned}$$

Como:

$$Q^\star(2, D) = \frac{52}{7} > Q^\star(2, E) = \frac{34}{7}$$

a ação D é superior na célula 2.

Célula 3:

$$\begin{aligned} Q^\star(3, E) &= 0{,}8[-1 + V^\star(2)] + 0{,}2(10) \\ &= 0{,}8\left(-1 + \frac{52}{7}\right) + 2 \\ &= \frac{50}{7} \approx 7{,}1429 \end{aligned}$$

Como:

$$Q^\star(3, D) = \frac{65}{7} > Q^\star(3, E) = \frac{50}{7}$$

a ação D também é superior na célula 3.

Portanto, a política proposta é de fato ótima, pois a ação D apresenta maior valor esperado em ambos os estados.

3.5 Item (e)

A política ótima do MDP consiste em escolher a ação D (direita) em ambos os estados não terminais:

$$\boxed{\pi^\star(s) = \begin{cases} D, & \text{se } s = 2, \\ D, & \text{se } s = 3. \end{cases}}$$

Conforme os resultados do item (d), os valores ótimos dos estados são:

$$V^\star(2) = \frac{52}{7} \approx 7{,}4286$$

$$V^\star(3) = \frac{65}{7} \approx 9{,}2857$$

O rover prefere atravessar o corredor porque a célula terminal 4 oferece uma recompensa de $+10$, superior à recompensa de $+4$ oferecida pela célula terminal 1.

Embora exista uma probabilidade de $0{,}2$ de escorregar na direção oposta à escolhida, a probabilidade de $0{,}8$ de avançar na direção desejada torna a ação D mais vantajosa.

Além disso, mesmo considerando as penalidades de -1 ao alcançar células não terminais, o valor esperado acumulado da política que segue para a direita permanece superior ao da política que escolhe a esquerda.

Portanto, a política ótima prioriza alcançar a célula 4, pois sua maior recompensa compensa os riscos e os custos associados ao deslocamento.

4 Exercício 4

Exercício 4 — Monte Carlo baseado em modelo

Agora o rover do Exercício 3 **não conhece** T nem R: ele só observa as tuplas (s, a, r, s') que coleta ao agir. Seguindo a política $\pi(2) = \pi(3) = \mathbf{D}$, foram registrados os cinco episódios abaixo (a notação é a mesma dos slides: s_{t-1}; a_t, r_t, s_t).

Episódio	Trajetória observada
1	2; **D**, −1, 3; **D**, +10, 4
2	2; **D**, −1, 3; **D**, −1, 2; **D**, −1, 3; **D**, +10, 4
3	2; **D**, +4, 1
4	2; **D**, −1, 3; **D**, +10, 4
5	2; **D**, −1, 3; **D**, +10, 4

(a) Conte quantas vezes cada par (s, a) foi executado e quantas vezes cada tripla (s, a, s') foi observada.

(b) Estime as probabilidades de transição pela regra de contagem $\hat{T}(s, a, s') = \frac{\#(s, a, s')}{\#(s, a)}$ e verifique que, para cada par (s, a), os valores somam 1.

(c) Estime $\hat{R}(s, a, s')$ e compare $\hat{T}$ e $\hat{R}$ com o modelo verdadeiro do Exercício 3. Qual dos dois pares (s, a) foi melhor estimado? Por quê?

(d) É possível estimar $\hat{T}(2, \mathbf{E}, \cdot)$ ou $\hat{T}(3, \mathbf{E}, \cdot)$ a partir desse registro? Justifique e nomeie o problema fundamental que isso ilustra.

4.1 Item (a)

Considerando os cinco episódios observados, realizamos a contagem das execuções de cada par estado-ação (s, a) e das ocorrências de cada transição (s, a, s').

Como a política utilizada é $\pi(2) = \pi(3) = D$, apenas a ação D foi executada nos episódios.

Contagem dos pares estado-ação:

Tabela 5: Número de execuções dos pares estado-ação

Par (s, a)	Número de execuções
$(2, D)$	6
$(3, D)$	5
Total	11

Contagem das transições observadas:

Tabela 6: Número de ocorrências das transições

s	a	s'	Ocorrências
2	D	3	5
2	D	1	1
3	D	4	4
3	D	2	1

Para o par $(2, D)$, foram observadas cinco transições para a célula 3 e uma transição para a célula 1:

$$\#(2, D) = 5 + 1 = 6$$

Para o par $(3, D)$, foram observadas quatro transições para a célula 4 e uma transição para a célula 2:

$$\#(3, D) = 4 + 1 = 5$$

Portanto, foram registradas 11 transições ao longo dos cinco episódios, considerando todas as ocorrências, inclusive as repetições dentro de um mesmo episódio.

4.2 Item (b)

As probabilidades de transição são estimadas pela frequência relativa das transições observadas nos episódios.

A regra de contagem é definida por:

$$\hat{T}(s, a, s') = \frac{\#(s, a, s')}{\#(s, a)}$$

em que $\#(s, a, s')$ representa o número de ocorrências da transição (s, a, s') e $\#(s, a)$ representa o número total de execuções do par estado-ação.

Transições a partir da célula 2:

Como o par $(2, D)$ foi executado seis vezes, sendo cinco transições para a célula 3 e uma para a célula 1, temos:

$$\hat{T}(2, D, 3) = \frac{5}{6} \approx 0{,}8333$$
$$\hat{T}(2, D, 1) = \frac{1}{6} \approx 0{,}1667$$

Transições a partir da célula 3:

Como o par $(3, D)$ foi executado cinco vezes, sendo quatro transições para a célula 4 e uma para a célula 2, temos:

$$\hat{T}(3, D, 4) = \frac{4}{5} = 0{,}8$$

$$\hat{T}(3, D, 2) = \frac{1}{5} = 0{,}2$$

A Tabela 7 apresenta as probabilidades estimadas.

Tabela 7: Probabilidades de transição estimadas

s	a	s'	$\hat{T}(s, a, s')$
2	D	3	$\frac{5}{6}$
2	D	1	$\frac{1}{6}$
3	D	4	$\frac{4}{5}$
3	D	2	$\frac{1}{5}$

Verificação das probabilidades:

Para o par $(2, D)$:

$$\begin{aligned}\sum_{s' \in S} \hat{T}(2, D, s') &= \frac{5}{6} + \frac{1}{6} \\ &= 1\end{aligned}$$

Para o par $(3, D)$:

$$\begin{aligned}\sum_{s' \in S} \hat{T}(3, D, s') &= \frac{4}{5} + \frac{1}{5} \\ &= 1\end{aligned}$$

Portanto, as probabilidades estimadas formam distribuições válidas, pois somam 1 para cada par estado-ação observado.

4.3 Item (c)

A recompensa estimada $\hat{R}(s, a, s')$ é obtida pela média das recompensas observadas para cada transição (s, a, s').

Assim:

$$\hat{R}(s, a, s') = \frac{\sum_{i=1}^{\#(s,a,s')} r_i}{\#(s, a, s')}$$

em que r_i representa a recompensa observada em cada ocorrência da transição.

Como todas as ocorrências de uma mesma transição apresentaram recompensas iguais, obtemos:

$$\hat{R}(2, D, 3) = -1$$
$$\hat{R}(2, D, 1) = +4$$
$$\hat{R}(3, D, 4) = +10$$
$$\hat{R}(3, D, 2) = -1$$

A Tabela 8 apresenta a comparação entre as probabilidades e recompensas estimadas e os valores verdadeiros do Exercício 3.

Tabela 8: Comparação entre o modelo estimado e o verdadeiro

s	a	s'	T	$\hat{T}$	R	$\hat{R}$
2	D	3	0,8	$\frac{5}{6}$	-1	-1
2	D	1	0,2	$\frac{1}{6}$	$+4$	$+4$
3	D	4	0,8	$\frac{4}{5}$	$+10$	$+10$
3	D	2	0,2	$\frac{1}{5}$	-1	-1

Observa-se que todas as recompensas foram estimadas exatamente:

$$\hat{R}(s, a, s') = R(s, a, s')$$

para todas as transições observadas.

Entretanto, as probabilidades de transição apresentam diferenças para o par $(2, D)$.

O erro absoluto das probabilidades estimadas para esse par é:

$$\left|\frac{5}{6} - 0{,}8\right| = \frac{1}{30} \approx 0{,}0333$$
$$\left|\frac{1}{6} - 0{,}2\right| = \frac{1}{30} \approx 0{,}0333$$

Já para o par $(3, D)$, as probabilidades estimadas coincidem exatamente com as probabilidades verdadeiras:

$$\hat{T}(3, D, 4) = T(3, D, 4) = 0{,}8$$
$$\hat{T}(3, D, 2) = T(3, D, 2) = 0{,}2$$

Portanto, o par $(3, D)$ foi melhor estimado nesta amostra, pois apresentou erro nulo nas probabilidades de transição, enquanto o par $(2, D)$ apresentou pequenas diferenças.

Essa diferença decorre da variabilidade aleatória das observações. Mesmo com menos execuções, o par $(3, D)$ apresentou frequências relativas iguais às probabilidades verdadeiras.

Isso não significa que menos observações produzam estimativas melhores, mas apenas que, nesta amostra específica, os resultados de $(3, D)$ coincidiram com o modelo verdadeiro.

4.4 Item (d)

Não é possível estimar as probabilidades de transição $\hat{T}(2, E, \cdot)$ e $\hat{T}(3, E, \cdot)$ a partir dos episódios fornecidos.

Isso ocorre porque todos os episódios foram gerados seguindo a política:

$$\pi(2) = \pi(3) = D$$

Portanto, a ação E nunca foi executada em nenhum dos estados observados.

Como a estimativa das probabilidades depende das frequências observadas:

$$\hat{T}(s, a, s') = \frac{\#(s, a, s')}{\#(s, a)}$$

para os pares $(2, E)$ e $(3, E)$, temos:

$$\#(2, E) = \#(3, E) = 0$$

Consequentemente, o denominador da expressão é zero, impossibilitando o cálculo dessas estimativas.

Essa situação ilustra o problema fundamental da **exploração versus explotação** (*exploration vs. exploitation*).

A exploração consiste em experimentar diferentes ações para obter informações sobre o ambiente, enquanto a explotação consiste em utilizar as ações consideradas mais vantajosas com base no conhecimento já adquirido.

Nesse caso, como o agente executou exclusivamente a ação D, não coletou informações suficientes para estimar o comportamento da ação E.

Portanto, seria necessário explorar também a ação E para estimar suas probabilidades de tran-

sição.

5 Exercício 5

Exercício 5 — Monte Carlo livre de modelo

Use **os mesmos cinco episódios** do Exercício 4, a mesma política $\pi(2) = \pi(3) = \mathbf{D}$ e $\gamma = 1$. Agora não vamos estimar o modelo: vamos estimar diretamente os Q-valores da política.

(a) Para cada episódio, calcule a utilidade $u_t = r_t + \gamma\, r_{t+1} + \gamma^2 r_{t+2} + \cdots$ de **todos** os passos t. Apresente os resultados em uma tabela com as colunas t, s_{t-1}, a_t, r_t e u_t.

(b) Calcule $\hat{Q}_\pi(2, \mathbf{D})$ e $\hat{Q}_\pi(3, \mathbf{D})$ pelo método ***first-visit***: para cada episódio, use apenas a *primeira* ocorrência de cada par (s, a) e faça a média dos u_t correspondentes.

(c) Compare os valores obtidos em (b) com os valores exatos $V^\star(2)$ e $V^\star(3)$ calculados no Exercício 3(d). Os valores são próximos? Que propriedade do estimador de Monte Carlo isso ilustra?

(d) Monte Carlo livre de modelo é *on-policy*. Explique o que isso significa e por que, se quiséssemos avaliar a política $\pi'(2) = \mathbf{E}$, esse mesmo registro seria inútil.

Dica

Em (a), calcule u_t *de trás para frente*: o último passo tem $u_T = r_T$ e, daí em diante, $u_t = r_t + \gamma\, u_{t+1}$. Em (b), o episódio 2 é o único em que algum par aparece mais de uma vez.

5.1 Item (a)

No método de Monte Carlo livre de modelo, a utilidade u_t representa a soma descontada das recompensas recebidas a partir do passo t até o final do episódio.

Sua expressão é dada por:

$$u_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots$$

Como o fator de desconto é $\gamma = 1$, a utilidade corresponde à soma de todas as recompensas restantes:

$$u_t = \sum_{k=t}^{T} r_k$$

em que T representa o último passo do episódio.

Episódio 1:

As recompensas observadas são $(-1, +10)$.

$$u_1 = -1 + 10 = 9$$
$$u_2 = 10$$

Episódio 2:

As recompensas observadas são $(-1, -1, -1, +10)$.

$$u_1 = -1 - 1 - 1 + 10 = 7$$
$$u_2 = -1 - 1 + 10 = 8$$
$$u_3 = -1 + 10 = 9$$
$$u_4 = 10$$

Episódio 3:

O episódio possui apenas uma transição, com recompensa $+4$.

$$u_1 = 4$$

Episódio 4:

As recompensas observadas são $(-1, +10)$.

$$u_1 = -1 + 10 = 9$$
$$u_2 = 10$$

Episódio 5:

As recompensas observadas são $(-1, +10)$.

$$u_1 = -1 + 10 = 9$$
$$u_2 = 10$$

Tabela de resultados:

A Tabela 9 apresenta as utilidades calculadas para todos os passos dos cinco episódios.

Tabela 9: Utilidades dos episódios de Monte Carlo

Episódio	t	s_{t-1}	a_t	r_t	u_t
1	1	2	D	-1	9
1	2	3	D	$+10$	10
2	1	2	D	-1	7
2	2	3	D	-1	8
2	3	2	D	-1	9
2	4	3	D	$+10$	10
3	1	2	D	$+4$	4
4	1	2	D	-1	9
4	2	3	D	$+10$	10
5	1	2	D	-1	9
5	2	3	D	$+10$	10

Portanto, as utilidades foram calculadas considerando o retorno acumulado de cada passo até o encerramento do respectivo episódio, sem a necessidade de estimar as probabilidades de transição do ambiente.

5.2 Item (b)

No método de Monte Carlo *first-visit*, o Q-valor de um par estado-ação (s, a) é estimado pela média das utilidades observadas na primeira ocorrência desse par em cada episódio.

A estimativa é dada por:

$$\hat{Q}_\pi(s,a) = \frac{1}{N(s,a)} \sum_{i=1}^{N(s,a)} u_i(s,a)$$

em que $N(s, a)$ representa o número de episódios nos quais o par (s, a) foi visitado, e $u_i(s, a)$ é a utilidade de sua primeira ocorrência no episódio i.

A Tabela 10 apresenta as utilidades consideradas para cada par.

Tabela 10: Utilidades consideradas no método first-visit

Episódio	$(2, D)$	$(3, D)$
1	9	10
2	7	8
3	4	–
4	9	10
5	9	10

Estimativa de $\hat{Q}_\pi(2, D)$:

O par $(2, D)$ aparece nos cinco episódios. Considerando apenas sua primeira ocorrência em cada um deles, temos:

$$\begin{aligned}\hat{Q}_\pi(2, D) &= \frac{9 + 7 + 4 + 9 + 9}{5} \\ &= \frac{38}{5} \\ &= 7{,}6\end{aligned}$$

Portanto:

$$\boxed{\hat{Q}_\pi(2, D) = 7{,}6}$$

Estimativa de $\hat{Q}_\pi(3, D)$:

O par $(3, D)$ aparece em quatro episódios, não sendo observado no episódio 3.

Considerando apenas a primeira ocorrência em cada episódio:

$$\begin{aligned}\hat{Q}_\pi(3, D) &= \frac{10 + 8 + 10 + 10}{4} \\ &= \frac{38}{4} \\ &= 9{,}5\end{aligned}$$

Portanto:

$$\boxed{\hat{Q}_\pi(3, D) = 9{,}5}$$

No episódio 2, os pares $(2, D)$ e $(3, D)$ aparecem mais de uma vez. Entretanto, pelo critério *first-visit*, somente as utilidades da primeira ocorrência de cada par são utilizadas.

Assim, os Q-valores estimados são:

$$\boxed{\begin{aligned}\hat{Q}_\pi(2, D) &= 7{,}6 \\ \hat{Q}_\pi(3, D) &= 9{,}5\end{aligned}}$$

5.3 Item (c)

No Exercício 3(d), foram obtidos os valores ótimos exatos:

$$V^\star(2) = \frac{52}{7} \approx 7{,}4286$$
$$V^\star(3) = \frac{65}{7} \approx 9{,}2857$$

No item (b), utilizando o método de Monte Carlo *first-visit*, obtivemos as estimativas:

$$\hat{Q}_\pi(2, D) = 7{,}6$$
$$\hat{Q}_\pi(3, D) = 9{,}5$$

Como a política utilizada é $\pi(2) = \pi(3) = D$, que corresponde à política ótima encontrada no Exercício 3, podemos comparar diretamente essas estimativas com os valores ótimos exatos.

Cálculo dos erros absolutos:

Para o estado 2:

$$\begin{aligned} E_2 &= \left| 7{,}6 - \frac{52}{7} \right| \\ &= \frac{6}{35} \\ &\approx 0{,}1714 \end{aligned}$$

Para o estado 3:

$$\begin{aligned} E_3 &= \left| 9{,}5 - \frac{65}{7} \right| \\ &= \frac{3}{14} \\ &\approx 0{,}2143 \end{aligned}$$

A Tabela 11 apresenta os resultados.

Tabela 11: Comparação entre os valores exatos e estimados

Estado	Valor exato	Estimativa MC	Erro absoluto
2	$7{,}4286$	$7{,}6000$	$0{,}1714$
3	$9{,}2857$	$9{,}5000$	$0{,}2143$

Observa-se que as estimativas de Monte Carlo são próximas dos valores exatos, mesmo utilizando apenas cinco episódios.

As pequenas diferenças decorrem da variabilidade aleatória das trajetórias observadas.

Esse resultado ilustra a propriedade de **consistência do estimador de Monte Carlo**.

À medida que o número de episódios independentes aumenta, a média das utilidades observadas tende a convergir para o valor esperado verdadeiro da política avaliada, conforme a Lei dos Grandes Números.

Portanto, embora as estimativas possam apresentar erros com poucas observações, elas tendem a se tornar mais precisas com o aumento da quantidade de episódios.

5.4 Item (d)

O método de Monte Carlo livre de modelo utilizado é classificado como *on-policy*, pois a política avaliada é a mesma utilizada para gerar os episódios de experiência.

Nesse método, os Q-valores são estimados a partir das recompensas acumuladas em trajetórias produzidas pela própria política π.

No exercício, todos os episódios foram gerados seguindo a política:

$$\pi(2) = \pi(3) = D$$

Portanto, as estimativas obtidas correspondem aos Q-valores dessa política.

Entretanto, caso desejássemos avaliar uma política alternativa π', definida por:

$$\pi'(2) = E$$

o mesmo registro não seria suficiente, pois a ação E nunca foi executada na célula 2.

Consequentemente, não existem observações do par $(2, E)$:

$$\#(2, E) = 0$$

Além disso, os retornos observados após executar a ação D não representam diretamente os retornos que seriam obtidos seguindo a política π'.

Assim, seria necessário gerar novos episódios seguindo a política π' para avaliá-la diretamente pelo método Monte Carlo *on-policy*.

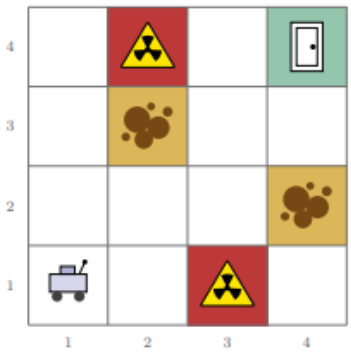
Essa limitação evidencia a dependência do método em relação à política utilizada na coleta dos dados.

Métodos *off-policy*, por outro lado, permitem avaliar uma política diferente daquela utilizada para gerar os episódios, desde que sejam atendidas as condições necessárias para essa avaliação.

6 Exercício 6

Exercício 6 — Q-Learning em uma grade 4×4

Um rover deve **escapar da área com o menor número de passos possível, sem atolar**. O ambiente é a grade 4×4 abaixo; as células são identificadas pelo par **(coluna, linha)**, com a **linha 1 na base** da figura.



Recompensas

- célula vazia: -1
- atoleiro: -5
- radiação: -20
- saída: $+20$ (terminal)

Parâmetros

$\alpha = 0{,}2 \quad \gamma = 0{,}95 \quad \epsilon = 0{,}1$

desempate: $\uparrow \rightarrow \downarrow \leftarrow$

Espaço de estados: as 16 células da grade. **Ações:** $\uparrow \rightarrow \downarrow \leftarrow$ (uma ação que levaria o rover para fora da grade *não está disponível* naquela célula). **Recompensa:** é determinada pela célula de *destino*, conforme a legenda. A célula de saída $(4,4)$ é o único estado terminal.

Condições de execução. Inicialize $Q(s,a) = 0$ para todo par (s,a) e use a atualização de Q-learning

$$Q(s,a) \leftarrow (1-\alpha)\,Q(s,a) + \alpha\Big[r + \gamma \max_{a' \in \mathcal{A}(s')} Q(s',a')\Big].$$

Embora a política de atuação seja ϵ-greedy com $\epsilon = 0{,}1$, **para o desenvolvimento dos episódios considere que a ação gananciosa é sempre a escolhida**. Em caso de empate entre Q-valores, use a ordem de desempate $\uparrow \rightarrow \downarrow \leftarrow$. Os estados iniciais de cada episódio são:

Episódio	1	2	3	4	5	6	7	8	9
Estado inicial	$(2,2)$	$(3,1)$	$(1,1)$	$(1,2)$	$(1,4)$	$(1,4)$	$(2,2)$	$(3,1)$	$(1,1)$

(a) Como estará a tabela Q no **início do 9° episódio**?

(b) Qual será o **trajeto** feito pelo agente no 9° episódio?

(c) Qual será a **recompensa total** no fim do 1° episódio? E do 7°?

(d) Considerando uma política ϵ-greedy, qual a probabilidade de a ação $\downarrow$ ser escolhida na célula $(4,3)$, caso visitada?

Dica

Os episódios 5 e 6 são longos (dezenas de passos), porque uma política puramente gananciosa sobre uma tabela Q ainda quase nula faz o agente vagar pela grade. Por isso, **implemente o laço de Q-learning em Python** e imprima a tabela Q e o trajeto de cada episódio; resolva à mão apenas o 1° episódio, para se certificar de que sua implementação reproduz as contas feitas em sala. No item (d), repare em quantas ações estão *disponíveis* na célula $(4,3)$ e verifique, na sua tabela Q, se $\downarrow$ é ou não a ação gananciosa ali.

6.1 Item (a)

Para determinar a tabela Q no início do nono episódio, executamos o algoritmo Q-Learning durante os oito primeiros episódios, utilizando os parâmetros:

$$\alpha = 0{,}2, \qquad \gamma = 0{,}95, \qquad \epsilon = 0{,}1$$

Inicialmente, todos os Q-valores são iguais a zero:

$$Q(s,a) = 0, \quad \forall (s,a)$$

Conforme solicitado, durante a execução dos episódios a ação escolhida é sempre a gananciosa, com desempate na ordem:

$$\uparrow, \quad \rightarrow, \quad \downarrow, \quad \leftarrow$$

A atualização utilizada é:

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha \left[r + \gamma \max_{a' \in A(s')} Q(s',a') \right]$$

Substituindo os parâmetros:

$$Q(s,a) \leftarrow 0{,}8Q(s,a) + 0{,}2 \left[r + 0{,}95 \max_{a' \in A(s')} Q(s',a') \right]$$

Nos estados terminais, o valor das recompensas futuras é zero.

Resultados dos oito episódios:

Tabela 12: Execução dos oito primeiros episódios

Episódio	Número de passos	Recompensa total
1	4	-6
2	4	$+17$
3	8	-10
4	5	$+12$
5	39	-83
6	23	-2
7	10	$+11$
8	6	$+11$

Tabela Q no início do nono episódio:

A Tabela 13 apresenta os Q-valores obtidos após a execução dos oito episódios, arredondados para quatro casas decimais.

Tabela 13: Tabela Q no início do nono episódio

Estado (x, y)	$Q(s, \uparrow)$	$Q(s, \rightarrow)$	$Q(s, \downarrow)$	$Q(s, \leftarrow)$
$(1, 1)$	$-0{,}9563$	$-0{,}7927$	–	–
$(2, 1)$	$-0{,}7752$	$-4{,}0000$	–	$-0{,}8936$
$(3, 1)$	$-0{,}3600$	$-0{,}5500$	–	$-0{,}2000$
$(4, 1)$	$-1{,}8000$	–	–	$-4{,}0000$
$(1, 2)$	$-0{,}9505$	$-0{,}9159$	$-0{,}7903$	–
$(2, 2)$	$-1{,}0000$	$-0{,}6443$	$-0{,}8156$	$-0{,}6315$
$(3, 2)$	$1{,}6287$	$-1{,}0000$	$-4{,}0380$	$-0{,}2380$
$(4, 2)$	$-0{,}2000$	–	$-0{,}2000$	$-0{,}0308$
$(1, 3)$	$-0{,}8519$	$-1{,}0000$	$-1{,}0058$	–
$(2, 3)$	$-4{,}0000$	$-0{,}0936$	$-0{,}2000$	$0{,}0000$
$(3, 3)$	$7{,}3045$	$0{,}0000$	$0{,}0000$	$0{,}0000$
$(4, 3)$	$4{,}0000$	–	$0{,}0000$	$0{,}0000$
$(1, 4)$	–	$-4{,}0000$	$-0{,}9379$	–
$(2, 4)$	–	$-0{,}2000$	$-1{,}0000$	$0{,}0000$
$(3, 4)$	–	$15{,}8057$	$0{,}0000$	$0{,}0000$
$(4, 4)$	–	–	–	–

Na tabela, o símbolo "–" indica uma ação indisponível naquela célula. O estado $(4, 4)$ é terminal e, portanto, não possui ações disponíveis.

Os valores iguais a zero correspondem a ações que ainda não receberam atualizações durante os episódios.

Observa-se que os maiores Q-valores estão próximos da saída $(4, 4)$, especialmente nos estados $(3, 4)$ e $(3, 3)$.

Isso ocorre porque o agente passa a incorporar às estimativas as recompensas positivas associadas à chegada ao estado terminal.

6.2 Item (b)

O nono episódio inicia no estado $(1, 1)$, utilizando a tabela Q obtida após os oito primeiros episódios.

Em cada passo, o agente seleciona a ação com maior Q-valor disponível:

$$a_t = \arg\max_{a \in A(s_t)} Q(s_t, a)$$

Em caso de empate, utiliza-se a ordem de prioridade:

$$\uparrow, \quad \rightarrow, \quad \downarrow, \quad \leftarrow$$

A Tabela 14 apresenta a sequência de movimentos realizada pelo agente.

Tabela 14: Trajeto do agente no nono episódio

Passo	Estado	Ação	Próximo estado	Recompensa
1	$(1,1)$	$\rightarrow$	$(2,1)$	-1
2	$(2,1)$	$\uparrow$	$(2,2)$	-1
3	$(2,2)$	$\leftarrow$	$(1,2)$	-1
4	$(1,2)$	$\downarrow$	$(1,1)$	-1
5	$(1,1)$	$\uparrow$	$(1,2)$	-1
6	$(1,2)$	$\rightarrow$	$(2,2)$	-1
7	$(2,2)$	$\rightarrow$	$(3,2)$	-1
8	$(3,2)$	$\uparrow$	$(3,3)$	-1
9	$(3,3)$	$\uparrow$	$(3,4)$	-1
10	$(3,4)$	$\rightarrow$	$(4,4)$	$+20$

O trajeto completo é:

$$\begin{aligned}(1,1) &\rightarrow (2,1) \rightarrow (2,2)\\ &\rightarrow (1,2) \rightarrow (1,1)\\ &\rightarrow (1,2) \rightarrow (2,2)\\ &\rightarrow (3,2) \rightarrow (3,3)\\ &\rightarrow (3,4) \rightarrow (4,4)\end{aligned}$$

O agente realiza dez movimentos até alcançar a saída $(4,4)$.

Durante o percurso, passa apenas por células vazias, recebendo nove penalidades de -1 e a recompensa terminal de $+20$.

Assim, a recompensa total do episódio é:

$$R_{\text{total}} = 9(-1) + 20$$

$$\boxed{R_{\text{total}} = 11}$$

Observa-se que o agente ainda realiza movimentos desnecessários, retornando a estados anteriormente visitados.

Isso ocorre porque a tabela Q ainda não convergiu para os valores ótimos, fazendo com que a política gananciosa apresente decisões subótimas durante o percurso.

6.3 Item (c)

A recompensa total de cada episódio é calculada pela soma das recompensas recebidas em todas as transições até alcançar o estado terminal.

$$R_{\text{total}} = \sum_{t=1}^{T} r_t$$

Episódio 1:

O agente parte do estado $(2, 2)$ e realiza o seguinte trajeto:

$$\begin{aligned}(2,2) &\to (2,3) \to (2,4) \\ &\to (3,4) \to (4,4)\end{aligned}$$

As recompensas recebidas são:

- $(2, 3)$: atoleiro, recompensa -5;
- $(2, 4)$: radiação, recompensa -20;
- $(3, 4)$: célula vazia, recompensa -1;
- $(4, 4)$: saída, recompensa $+20$.

Assim:

$$\begin{aligned}R_{\text{total}}^{(1)} &= -5 - 20 - 1 + 20 \\ &= -6\end{aligned}$$

Portanto:

$$\boxed{R_{\text{total}}^{(1)} = -6}$$

Episódio 7:

O agente parte novamente do estado $(2, 2)$ e realiza o trajeto:

$$
\begin{aligned}
(2,2) &\to (2,1) \to (1,1) \\
&\to (1,2) \to (1,3) \\
&\to (1,2) \to (2,2) \\
&\to (3,2) \to (3,3) \\
&\to (3,4) \to (4,4)
\end{aligned}
$$

Nesse episódio, o agente realiza dez movimentos, sendo nove transições para células vazias, com recompensa -1, e uma transição para a saída, com recompensa $+20$.

Logo:

$$
\begin{aligned}
R_{\text{total}}^{(7)} &= 9(-1) + 20 \\
&= -9 + 20 \\
&= 11
\end{aligned}
$$

Portanto:

$$
\boxed{R_{\text{total}}^{(7)} = 11}
$$

Comparação dos resultados:

$$
\begin{aligned}
R_{\text{total}}^{(1)} &= -6 \\
R_{\text{total}}^{(7)} &= 11
\end{aligned}
$$

A diferença entre as recompensas é:

$$
\Delta R = 11 - (-6) = 17
$$

Assim, o episódio 7 apresenta uma recompensa total 17 unidades maior que o episódio 1.

Essa melhoria ocorre porque, após as atualizações da tabela Q, o agente passa a evitar as células com maiores penalidades.

Embora o trajeto do episódio 7 seja mais longo, ele produz uma recompensa total superior por evitar o atoleiro e a radiação.

6.4 Item (d)

Na política ϵ-greedy, o agente seleciona a ação gananciosa com probabilidade $1 - \epsilon$ e realiza uma escolha aleatória entre as ações disponíveis com probabilidade ϵ.

Considerando $\epsilon = 0{,}1$, analisamos o estado $(4, 3)$.

Nessa célula, as ações disponíveis são:

$$A((4,3)) = \{\uparrow, \downarrow, \leftarrow\}$$

A ação $\rightarrow$ não está disponível, pois levaria o agente para fora da grade.

Conforme a tabela Q obtida no item (a):

$$\begin{aligned} Q((4,3), \uparrow) &= 4 \\ Q((4,3), \downarrow) &= 0 \\ Q((4,3), \leftarrow) &= 0 \end{aligned}$$

Portanto, a ação gananciosa é:

$$a^\star = \uparrow$$

Como a ação $\downarrow$ não é gananciosa, ela somente pode ser selecionada durante a exploração aleatória.

Na definição de ϵ-greedy em que a exploração sorteia uniformemente entre todas as ações disponíveis, temos:

$$P(\downarrow | \ (4,3)) = \frac{\epsilon}{|A((4,3))|}$$

Substituindo os valores:

$$\begin{aligned} P(\downarrow | \ (4,3)) &= \frac{0{,}1}{3} \\ &\approx 0{,}0333 \end{aligned}$$

Portanto:

$$\boxed{P(\downarrow | \ (4,3)) \approx 3{,}33\%}$$

Assim, a probabilidade de escolher a ação $\downarrow$ na célula $(4, 3)$ é aproximadamente $3{,}33\%$.